AI-маркетолог сокращает запуск кампании с 9 дней до ≈1,3, а уровень автоматизации растёт только после доказательств безопасности

9 → ≈1,3 дня

запуск шаблонной кампании

- **Новые кампании с юридической очередью: 2,7 дня;**
- **В смеси 50/50 — 1,7 дня**;

−33%…63%

время от гипотезы до подтверждённого результата

***при окне наблюдения 28…7 дней**

≈13,5 млн ₽

стоимость пилота

***5 человек × 0,35 × 6 мес. + инфраструктура и резерв**

Что просим решить:
запустить пилот на 6 месяцев командой из 5 человек. Право отказаться от масштабирования в М6 стоит ≈13,5 млн ₽, а не стоимость внедрения на весь контур.

Метки достоверности: FACT — условие кейса · MODEL — расчёт репозитория · ASSUMPTION — рабочее допущение, проверяемое пилотом

Главный резерв модели — убрать ожидание между ролями, а не сокращать работу людей

СЕЙЧАС: 9 дней запуска + 5 дней разбор

Гипотеза	Анализ	Сегмент	Оффер	Креативы	Проверка + юрист	Запуск	Разбор
1+ дн	2 дн	1 дн	1–2 дн	2 дн	1 дн	3 дн	5 дн

Рабочая гипотеза для декомпозиции: 3 дня активной работы + 6 дней ожидания;

СТАНЕТ: шаблонная кампания, p50 по модели

Приём	Аудитория	Оффер и креатив	Проверки	Один клик	Пробный запуск 3%
0,15 дн	0,25 дн	0,20 дня, параллельно	0,25 дн	0,10 дн	0,35 дн

Шаблонная кампания: 1,3 дня (p90 1,5)
шаблон согласован заранее — юриста в потоке нет

Новая кампания: 2,7 дня (p90 3,6)
добавляется очередь юриста 0,5–1–3 дня; в смеси 50/50: p50 1,7, p90 3,3

До подтверждённого результата выигрыш меньше, потому что окно наблюдения не сжимается: −63% при окне 7 дней, −48% при 14, −33% при 28.

FACT MODEL ASSUMPTION

«3 + 6» и очередь юриста — ASSUMPTION.

AI берёт рутину 7 шагов и разбора итогов, а маркетолог, аналитик и редактор переходят к решениям

Шаг	Делает AI	Остаётся человеку
1 Гипотеза	идеи из истории и данных, оценка	выбор стратегии, сезонные акции
2 Анализ	размер аудитории, прогноз эффекта и риска	go / no-go
3 Сегмент	аудитория, холдаут, контактная политика	нестандартные сегменты
4 Оффер	оффер из каталога, канал, сценарий	новые условия и деньги клиента
5 Креативы	тексты внутри согласованных шаблонов	новые шаблоны, тон бренда
6 Проверка	правила, судья, бюджет, политика	спорные случаи, юристы
7 Запуск	карточка, пробный запуск, откат	подтверждение отправки
Разбор итогов	предварительное чтение на следующий день, uplift	выводы и следующая гипотеза

Маркетолог
из исполнителя в владельца гипотез, исключений и новых условий

Аналитик
из сборщика выборок в владельца экспериментов и порогов

Редактор
из автора текстов в куратора шаблонов, тона и формулировок

FACT ASSUMPTION

120 кампаний/мес. — факт кейса; 2 ч ручной проверки на кампанию — допущение. Сценарий даёт ≈1,4 FTE и проверяется shadow-замером

Campaign OS: код проверяет факты, ML выбирает контакт, LLM пишет, независимый судья ловит остаточный риск

Данные
каталог офферов, согласия, история контактов

→

Правила (код)
доступность оффера, политика, бюджет, числа и даты

→

Causal ML
uplift: кому писать и в каком канале

→

LLM
гипотезы и текст внутри шаблона

→

Судья
другая модель: смысл и тон

→

Оркестратор
пробный запуск, откат, kill switch, журнал

Контур человека:
одобрить / изменить / отклонить · исключения · граница автономности · решения по инцидентам. В пилоте агент не отправляет сообщения сам: каждую отправку подтверждает человек.

20,5% → 0%

клиентов нарушают политику при 3 сообщениях в неделю, если кампании проверяют только себя; центральный арбитр: 0% ценой 7,4% ценности

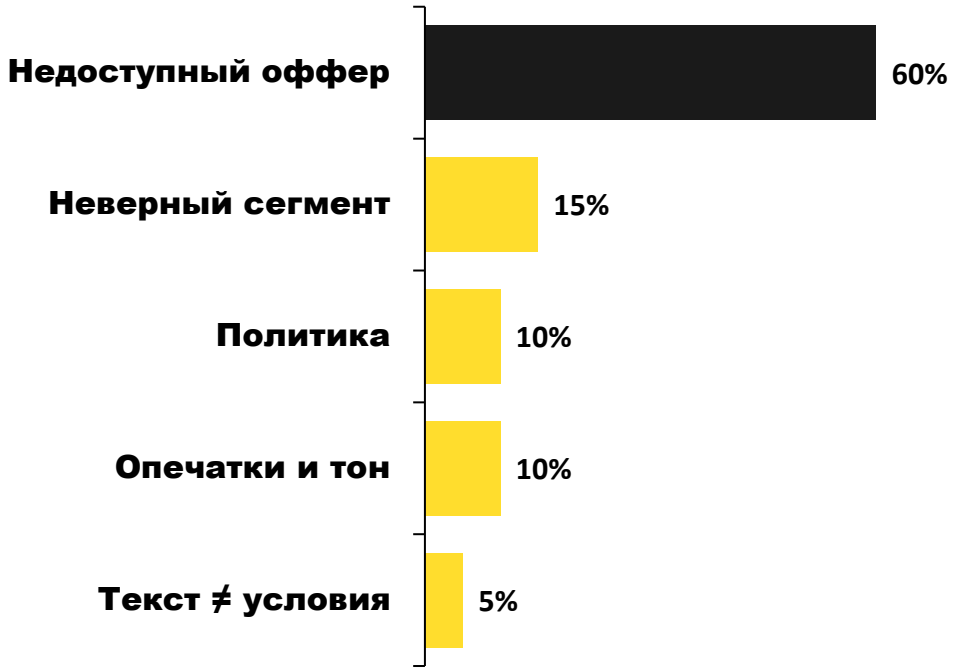
Где достаточно обычных правил:

всё, что проверяется однозначно. ML и LLM нужны только там, где правила не работают: выбор аудитории, генерация, смысловая проверка. Если компонент недоступен, система не угадывает, а останавливает кампанию или передаёт её человеку.

MODEL

Расчёт: contact_policy.py — 20 000 клиентов × 5 недель, синтетическая симуляция; сервисы Города делят один лимит

При рабочей таксономии основной риск — недоступный оффер; код ловит факты, Judge — смысл и тон



Класс ошибок	Кто ловит	Цель
Недоступный оффер	код: проверка допустимости до отправки	≥ 95%
Политика	центральный арбитр	0 по построению
Текст ≠ условия	условия из каталога + сверка кодом	любое расхождение — блок
Опечатки и тон	LLM-судья на другой модели	≥ 85%

Масштаб: 120 кампаний × 1,5% × 60% ≈ 1,1
кампании в месяц ≈ 0,3 млн клиентов (охват ≈300 тыс.)

Как проверяем самого судью

- судья — другая модель, чем генератор; критические факты проверяет код
- золотой набор не менее 149 критических примеров и независимая выборка человеком
- каппа с экспертами ≥ 0,7; еженедельный прогон; при падении — отключение Green

Модельный минимум для класса «опечатки и тон» — 84,4% при рабочей таксономии; operational target пилота ≥85%. Диапазон чувствительности: 72–98%.

ASSUMPTION DERIVED TARGET

Таксономия ошибок и охват контролей — ASSUMPTION до разметки реального журнала; цель Judge рассчитывает judge_target.py

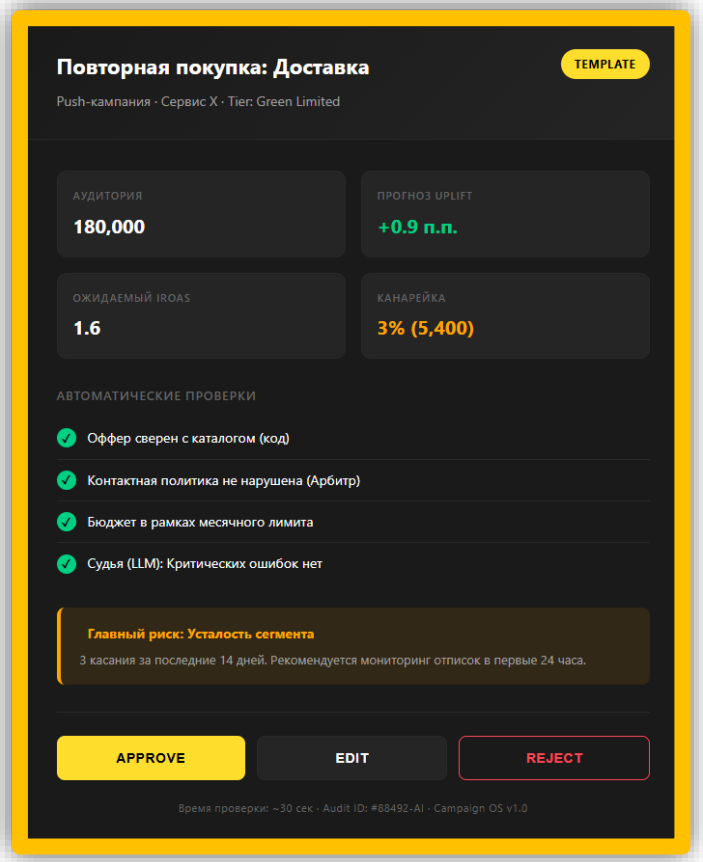
Право на больший охват зарабатывается доказательствами, но отправку в пилоте подтверждает человек

GREEN_READY = шаблон согласован ✓ · оффер доступен ✓ · политика ✓ · судья ✓ · низкий риск ✓ · охват в лимите ✓ · error budget в норме ✓

L1 Один клик
59 безошибочных → граница ошибок 5%

L2 Green limited
149 → ≤2%; охват 0,5 млн без канарейки, 4,0 млн с канарейкой

L2 Green standard
299 → ≤1%; охват 1,0 / 7,9 млн



Понижение — сразу:

- **Критический инцидент = стоп и понижение;**
- **В пилоте человек подтверждает каждую отправку**

MODEL ASSUMPTION

Расчёты: autonomy.py, error_budget.py. Ущерб 1 ₽ на контакт, ED_max 10 000 ₽, канарейка 3%, обнаружение 90% — допущения

Мы докажем два разных факта: кампания даёт инкрементальный GMV, а ИИ не хуже человека

1 Кампания против холдаута

Метрика	Клиентов на ветку	С CUPED
Конверсия (прокси)	8 155	5 709
GMV, вариация чека 1	16 789	11 753
GMV, вариация чека 2	42 691	29 884
GMV, вариация чека 3	85 859	60 102

Главная метрика — инкрементальный GMV: при вариации чека 2 выборка в 5 раз больше, чем для конверсии.

2 ИИ против человека (неухудшение)

Допуск	Чек = 1	Чек = 2
30% эффекта (0,3 п.п.)	159 923	407 225
20% эффекта (0,2 п.п.)	359 825	916 255
10% эффекта (0,1 п.п.)	1 439 300	3 665 020

Non-inferiority по GMV: при CV=2 и допуске 30% нужно ≈407 тыс. клиентов на ветку

MODEL ASSUMPTION

Расчёты: experiment_design.py, gmv_sample_size.py.

Экономика зависит от охвата: ≈15 мес. при полном eligible-контуре и ≈24 мес. при 50%

15 мес

Полный eligible-контур, conservative: p50 15 мес.;

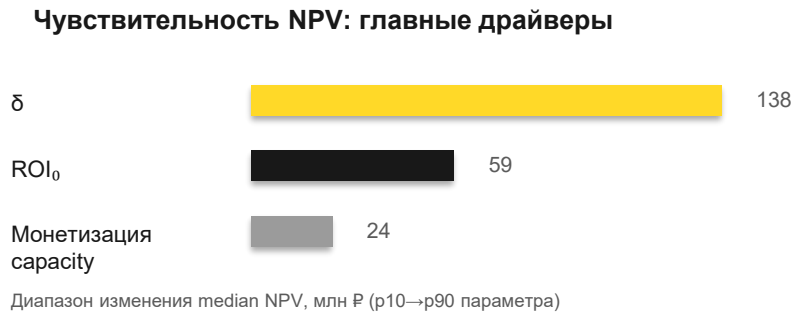
24 мес

Если адресуемо только 50% eligible-ценности: conservative p50 24 мес.;

12 мес

Base при полном eligible-контуре: + монетизированная ёмкость;

Затраты и стресс-сценарий	Значение
Пилот gross (6 мес.)	13,5 млн ₽ (12,4–15,7)
Содержание после пилота	1,45 млн ₽/мес
Uplift = 0: потеря при остановке в M6	≈13,8 (консерв.) / 12,5 (база) млн ₽
Uplift = 0: если не останавливать, NPV 24 мес.	-35 / -12 млн ₽



MODEL ASSUMPTION

Расчёты: economics.py · 50 000 Monte Carlo · sensitivity: полный eligible-контур vs 50% eligible-ценности

Три риска из ТЗ закрыты контролями и порогами остановки, а ошибка ограничена пробным запуском 3% и откатом

Риск из ТЗ	Контроль	Порог остановки
Выдуманные условия оффера	условия подставляются из каталога шаблоном; числа и даты сверяет код; судья читает текст	любое расхождение — блок; критический инцидент — стоп тира
Нарушение контактной политики	центральный арбитр на уровне клиента, отказы от рекламы исключаются	любое нарушение (>0) — стоп отправки
Сбой тона бренда	рубрика судьи на другой модели, золотой набор, выборка редакции	recall судьи < 75% — отключение Green; норма ≥ 85%

Если ошибка всё же ушла клиентам

1 Остановить
очередь на шлюзе, цель ≤ 5 мин

2 Оценить
охват и тяжесть, ≤ 1 ч

3 Откатить
условия и промокоды

4 Уведомить
клиентов и владельцев, ≤ 4 ч

5 Разобрать
причины, пример в золотой набор

6 Понизить
тир до L1, повторное повышение только по правилу

Остаточные главные риски: рост отдачи ниже безубыточного, общие ошибки судьи и генератора, неверная оценка эффекта на малых выборках. Все сценарии red team (поддельный оффер, устаревший список отказов, повторная отправка, prompt injection) имеют статус PLANNED, а не PASS.

MODEL ASSUMPTION

Расчёт: risk_register.py. FMEA 14 рисков; S/O/D — экспертные допущения для ранжирования, а не измеренные вероятности

Пять человек за шесть месяцев проходят путь от safety к ограниченной автоматизации, начиная с push и in-app

M1–M2
Безопасно ли?
правила, золотой набор, судья, shadow

M3
Используют ли?
карточка одного клика, adoption

M4–M5
Даёт ли эффект?
холдаут, CUPED, неухудшение, guardrails

M6
Масштабировать?
гейт по порогам

Команда 5 человек	Что делает
Владелец продукта	решения, юристы, внедрение, экономика
ML / causal инженер	uplift, эксперименты, пороги
LLM-инженер	агенты, судья, золотой набор
Backend и данные	оркестратор, арбитр, интеграции
Дизайнер-исследователь	карточка одного клика, adoption

Что запускаем первым
Волна 1 — 20% типов
волна 2 — ещё 30%;

Как добиваемся использования
цель adoption ≥70% среди eligible-кампаний к M5;

ASSUMPTION TARGET

Расчёт: portfolio.py.

Каждый месяц пилота снимает одну неопределённость и меняет следующее решение

Неизвестное	Тест	Свидетельство	Срок	Решение
Судья достаточно безопасен?	золотой набор + независимая разметка	recall тона ≥ 85%; каппа ≥ 0,7	M2	L0 → L1
Люди используют продукт?	телеметрия карточки одного клика	adoption, доля правок, время утверждения	M3	доработка интерфейса
ИИ не хуже человека?	ИИ / человек / холдаут	нижняя граница ДИ неухудшения	M5	следующий rollout
Эффект AI vs human?	AI / human / holdout	δ + 95% ДИ; payback	M5–M6	extend / scale / stop
Риск стабилен?	error budget и SPRT	расход бюджета ошибок, инциденты	постоянно	повысить или понизить тир

Пилот покупает информацию: если эффект не подтверждается, мы прекращаем масштабирование, потратив только стоимость пилота.

Через 6 месяцев — не «AI работает», а решение: масштабировать, дорабатывать или остановить, если выполнены все условия

Масштабировать

- AI не хуже человека по GMV; safety в норме
- $\hat{\delta} > 0$; обновлённая экономика привлекательна
- full rollout — только когда ДИ поддерживает break-even
- к ≥ 0,7; adoption ≥70% среди eligible; запуск ≤2 дней

Дорабатывать

- $\hat{\delta} > 0$, но ДИ включает break-even
- мощности недостаточно для экономического вывода
- при 50% eligible экономика слабее
- adoption среди eligible ниже цели

Остановить

- критический инцидент без устранённой причины
- рост отдачи ≤ 0 при достаточной мощности
- затраты пилота выше 15,7 млн ₽
- судья ниже порога после повторной калибровки

Пилот ≈13,5 млн ₽ gross — цена права не масштабировать.
При широкой ДИ расширяем только контролируемый эксперимент.