AI-маркетолог сокращает запуск кампании с 9 дней до ≈1,3, а уровень автоматизации растёт только после доказательств безопасности

9 → ≈1,3 дня

запуск шаблонной кампании

- **Новые кампании с юридической очередью: 2,7 дня;**
- **В смеси 50/50 — 1,7 дня**;

−33%…63%

время от гипотезы до подтверждённого результата

***при окне наблюдения 28…7 дней**

≈13,5 млн ₽

стоимость пилота

***5 человек × 0,35 × 6 мес. + инфраструктура и резерв**

Что просим решить:
запустить пилот на 6 месяцев командой из 5 человек. Право отказаться от масштабирования в М6 стоит ≈13,5 млн ₽, а не стоимость внедрения на весь контур.

Метки достоверности: FACT — условие кейса · MODEL — расчёт репозитория · ASSUMPTION — рабочее допущение, проверяемое пилотом

Главный резерв модели — убрать ожидание между ролями, а не сокращать работу людей

СЕЙЧАС: 9 дней запуска + 5 дней разбор

Гипотеза	Анализ	Сегмент	Оффер	Креативы	Проверка + юрист	Запуск	Разбор
1+ дн	2 дн	1 дн	1–2 дн	2 дн	1 дн	3 дн	5 дн

Рабочая гипотеза для декомпозиции: 3 дня активной работы + 6 дней ожидания;

СТАНЕТ: шаблонная кампания, p50 по модели

Приём	Аудитория	Оффер и креатив	Проверки	Один клик	Пробный запуск 3%
0,15 дн	0,25 дн	0,20 дня, параллельно	0,25 дн	0,10 дн	0,35 дн

Шаблонная кампания: 1,3 дня (p90 1,5)
шаблон согласован заранее — юриста в потоке нет

Новая кампания: 2,7 дня (p90 3,6)
добавляется очередь юриста 0,5–1–3 дня; в смеси 50/50: p50 1,7, p90 3,3

До подтверждённого результата выигрыш меньше, потому что окно наблюдения не сжимается: −63% при окне 7 дней, −48% при 14, −33% при 28.

FACT MODEL ASSUMPTION

«3 + 6» и очередь юриста — ASSUMPTION.

AI берёт рутину 7 шагов и разбора итогов, а маркетолог, аналитик и редактор переходят к решениям

Шаг	Делает AI	Остаётся человеку
1 Гипотеза	идеи из истории и данных, оценка	выбор стратегии, сезонные акции
2 Анализ	размер аудитории, прогноз эффекта и риска	go / no-go
3 Сегмент	аудитория, холдаут, контактная политика	нестандартные сегменты
4 Оффер	оффер из каталога, канал, сценарий	новые условия и деньги клиента
5 Креативы	тексты внутри согласованных шаблонов	новые шаблоны, тон бренда
6 Проверка	правила, судья, бюджет, политика	спорные случаи, юристы
7 Запуск	карточка, пробный запуск, откат	подтверждение отправки
Разбор итогов	предварительное чтение на следующий день, uplift	выводы и следующая гипотеза

Маркетолог
из исполнителя в владельца гипотез, исключений и новых условий

Аналитик
из сборщика выборок в владельца экспериментов и порогов

Редактор
из автора текстов в куратора шаблонов, тона и формулировок

FACT ASSUMPTION

120 кампаний/мес. — факт кейса; 2 ч ручной проверки на кампанию — допущение. Сценарий даёт ≈1,4 FTE и проверяется shadow-замером

Campaign OS: код проверяет факты, ML выбирает контакт, LLM пишет, независимый судья ловит остаточный риск

Данные
каталог офферов, согласия, история контактов

→

Правила (код)
доступность оффера, политика, бюджет, числа и даты

→

Causal ML
uplift: кому писать и в каком канале

→

LLM
гипотезы и текст внутри шаблона

→

Судья
другая модель: смысл и тон

→

Оркестратор
пробный запуск, откат, kill switch, журнал

Контур человека:
одобрить / изменить / отклонить · исключения · граница автономности · решения по инцидентам. В пилоте агент не отправляет сообщения сам: каждую отправку подтверждает человек.

20,5% → 0%

клиентов нарушают политику при 3 сообщениях в неделю, если кампании проверяют только себя; центральный арбитр: 0% ценой 7,4% ценности

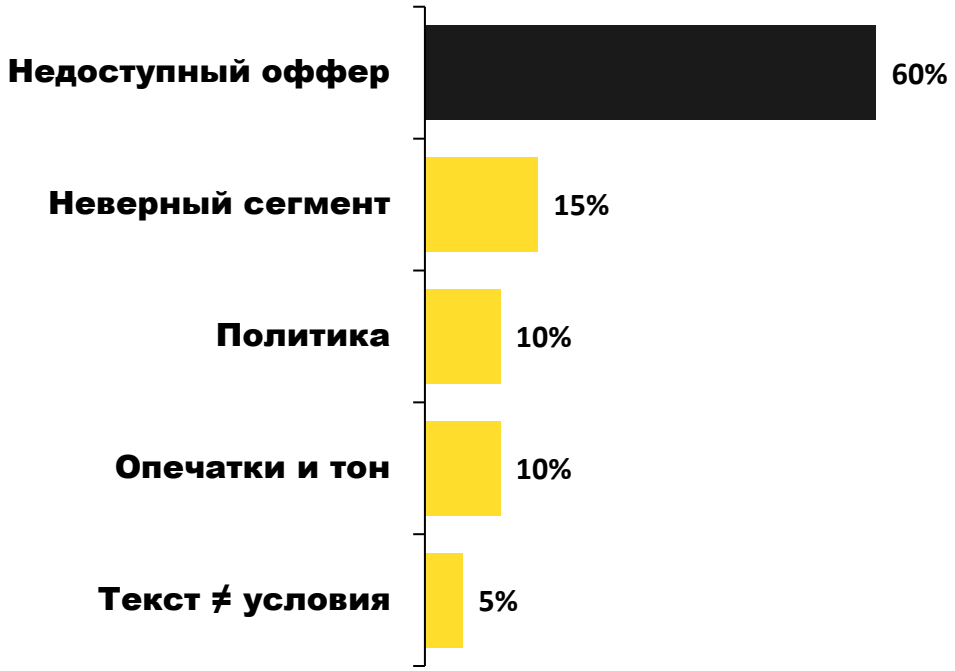
Где достаточно обычных правил:

всё, что проверяется однозначно. ML и LLM нужны только там, где правила не работают: выбор аудитории, генерация, смысловая проверка. Если компонент недоступен, система не угадывает, а останавливает кампанию или передаёт её человеку.

MODEL

Расчёт: contact_policy.py — 20 000 клиентов × 5 недель, синтетическая симуляция; сервисы Города делят один лимит

При рабочей таксономии основной риск — недоступный оффер; код ловит факты, Judge — смысл и тон



Класс ошибок	Кто ловит	Цель
Недоступный оффер	код: проверка допустимости до отправки	≥ 95%
Политика	центральный арбитр	0 по построению
Текст ≠ условия	условия из каталога + сверка кодом	любое расхождение — блок
Опечатки и тон	LLM-судья на другой модели	≥ 85%

Масштаб: 120 кампаний × 1,5% × 60% ≈ 1,1
кампании в месяц ≈ 0,3 млн клиентов (охват ≈300 тыс.)

Как проверяем самого судью

- судья — другая модель, чем генератор; критические факты проверяет код
- золотой набор не менее 149 критических примеров и независимая выборка человеком
- каппа с экспертами ≥ 0,7; еженедельный прогон; при падении — отключение Green

Модельный минимум для класса «опечатки и тон» — 84,4% при рабочей таксономии; operational target пилота ≥85%. Диапазон чувствительности: 72–98%.

ASSUMPTION DERIVED TARGET

Таксономия ошибок и охват контролей — ASSUMPTION до разметки реального журнала; цель Judge рассчитывает judge_target.py

Право на больший охват зарабатывается доказательствами, но отправку в пилоте подтверждает человек

GREEN_READY = шаблон согласован ✓ · оффер доступен ✓ · политика ✓ · судья ✓ · низкий риск ✓ · охват в лимите ✓ · error budget в норме ✓

L1 Один клик

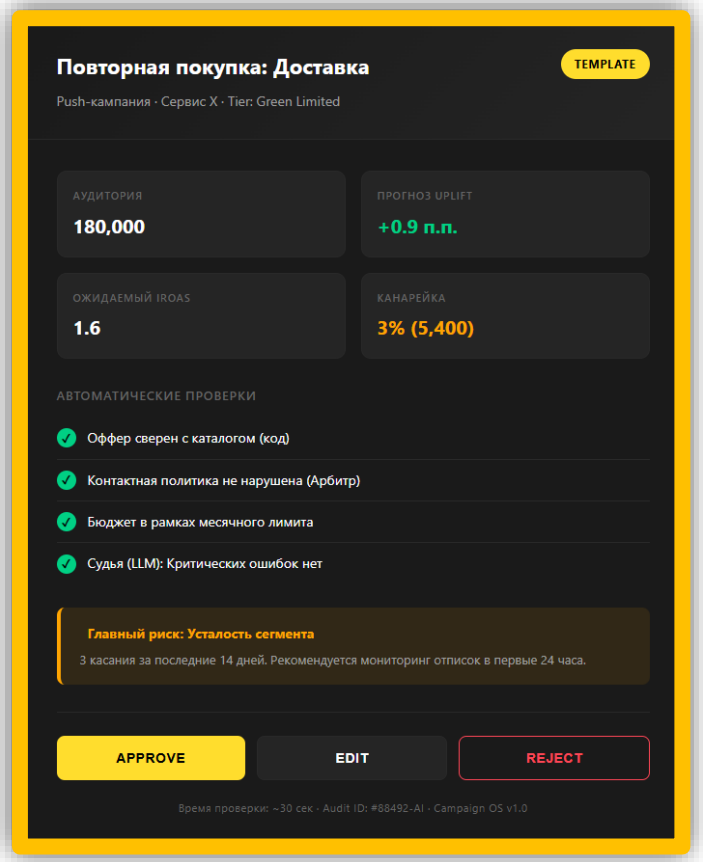
59 безошибочных → граница ошибок 5%

L2 Green limited

149 → ≤2%; охват 0,5 млн без канарейки, 4,0 млн с канарейкой

L2 Green standard

299 → ≤1%; охват 1,0 / 7,9 млн



Понижение — сразу:

- **Критический инцидент = стоп и понижение;**
- **В пилоте человек подтверждает каждую отправку**

MODEL ASSUMPTION

Расчёты: autonomy.py, error_budget.py. Ущерб 1 ₽ на контакт, ED_max 10 000 ₽, канарейка 3%, обнаружение 90% — допущения

Мы докажем два разных факта: кампания даёт инкрементальный GMV, а ИИ не хуже человека

1 Кампания против холдаута

Метрика	Клиентов на ветку	С CUPED
Конверсия (прокси)	8 155	5 709
GMV, вариация чека 1	16 789	11 753
GMV, вариация чека 2	42 691	29 884
GMV, вариация чека 3	85 859	60 102

Главная метрика — инкрементальный GMV: при вариации чека 2 выборка в 5 раз больше, чем для конверсии.

2 ИИ против человека (неухудшение)

Допуск	Чек = 1	Чек = 2
30% эффекта (0,3 п.п.)	159 923	407 225
20% эффекта (0,2 п.п.)	359 825	916 255
10% эффекта (0,1 п.п.)	1 439 300	3 665 020

Non-inferiority по GMV: при CV=2 и допуске 30% нужно ≈407 тыс. клиентов на ветку

MODEL ASSUMPTION

Расчёты: experiment_design.py, gmv_sample_size.py.

Экономика зависит от охвата: ≈15 мес. при полном eligible-контуре и ≈24 мес. при 50%

15 мес

Полный eligible-контур, conservative: p50 15 мес.;

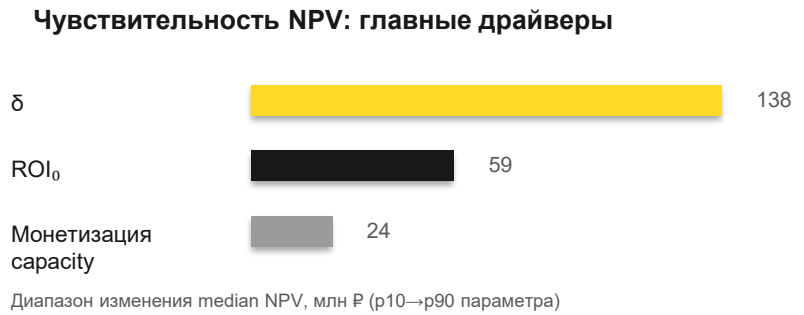
24 мес

Если адресуемо только 50% eligible-ценности: conservative p50 24 мес.;

12 мес

Base при полном eligible-контуре: + монетизированная ёмкость;

Затраты и стресс-сценарий	Значение
Пилот gross (6 мес.)	13,5 млн ₽ (12,4–15,7)
Содержание после пилота	1,45 млн ₽/мес
Uplift = 0: потеря при остановке в M6	≈13,8 (консерв.) / 12,5 (база) млн ₽
Uplift = 0: если не останавливать, NPV 24 мес.	-35 / -12 млн ₽



MODEL ASSUMPTION

Расчёты: economics.py · 50 000 Monte Carlo · sensitivity: полный eligible-контур vs 50% eligible-ценности

Три риска из ТЗ закрыты контролями и порогами остановки, а ошибка ограничена пробным запуском 3% и откатом

Риск из ТЗ	Контроль	Порог остановки
Выдуманные условия оффера	условия подставляются из каталога шаблоном; числа и даты сверяет код; судья читает текст	любое расхождение — блок; критический инцидент — стоп тира
Нарушение контактной политики	центральный арбитр на уровне клиента, отказы от рекламы исключаются	любое нарушение (>0) — стоп отправки
Сбой тона бренда	рубрика судьи на другой модели, золотой набор, выборка редакции	recall судьи < 75% — отключение Green; норма ≥ 85%

Если ошибка всё же ушла клиентам

1 Остановить
очередь на шлюзе, цель ≤ 5 мин

2 Оценить
охват и тяжесть, ≤ 1 ч

3 Откатить
условия и промокоды

4 Уведомить
клиентов и владельцев, ≤ 4 ч

5 Разобрать
причины, пример в золотой набор

6 Понизить
тир до L1, повторное повышение только по правилу

Остаточные главные риски: рост отдачи ниже безубыточного, общие ошибки судьи и генератора, неверная оценка эффекта на малых выборках. Все сценарии red team (поддельный оффер, устаревший список отказов, повторная отправка, prompt injection) имеют статус PLANNED, а не PASS.

MODEL ASSUMPTION

Расчёт: risk_register.py. FMEA 14 рисков; S/O/D — экспертные допущения для ранжирования, а не измеренные вероятности

Пять человек за шесть месяцев проходят путь от safety к ограниченной автоматизации, начиная с push и in-app

M1–M2
Безопасно ли?
правила, золотой набор, судья, shadow

M3
Используют ли?
карточка одного клика, adoption

M4–M5
Даёт ли эффект?
холдаут, CUPED, неухудшение, guardrails

M6
Масштабировать?
гейт по порогам

Команда 5 человек	Что делает
Владелец продукта	решения, юристы, внедрение, экономика
ML / causal инженер	uplift, эксперименты, пороги
LLM-инженер	агенты, судья, золотой набор
Backend и данные	оркестратор, арбитр, интеграции
Дизайнер-исследователь	карточка одного клика, adoption

Что запускаем первым
Волна 1 — 20% типов
волна 2 — ещё 30%;

Как добиваемся использования
цель adoption ≥70% среди eligible-кампаний к M5;

ASSUMPTION TARGET

Расчёт: portfolio.py.

Каждый месяц пилота снимает одну неопределённость и меняет следующее решение

Неизвестное	Тест	Свидетельство	Срок	Решение
Судья достаточно безопасен?	золотой набор + независимая разметка	recall тона ≥ 85%; каппа ≥ 0,7	M2	L0 → L1
Люди используют продукт?	телеметрия карточки одного клика	adoption, доля правок, время утверждения	M3	доработка интерфейса
ИИ не хуже человека?	ИИ / человек / холдаут	нижняя граница ДИ неухудшения	M5	следующий rollout
Эффект AI vs human?	AI / human / holdout	δ + 95% ДИ; payback	M5–M6	extend / scale / stop
Риск стабилен?	error budget и SPRT	расход бюджета ошибок, инциденты	постоянно	повысить или понизить тир

Пилот покупает информацию: если эффект не подтверждается, мы прекращаем масштабирование, потратив только стоимость пилота.

Через 6 месяцев — не «AI работает», а решение: масштабировать, дорабатывать или остановить, если выполнены все условия

Масштабировать

- AI не хуже человека по GMV; safety в норме
- $\hat{\delta} > 0$; обновлённая экономика привлекательна
- full rollout — только когда ДИ поддерживает break-even
- к ≥ 0,7; adoption ≥70% среди eligible; запуск ≤2 дней

Дорабатывать

- $\hat{\delta} > 0$, но ДИ включает break-even
- мощности недостаточно для экономического вывода
- при 50% eligible экономика слабее
- adoption среди eligible ниже цели

Остановить

- критический инцидент без устранённой причины
- рост отдачи ≤ 0 при достаточной мощности
- затраты пилота выше 15,7 млн ₽
- судья ниже порога после повторной калибровки

Пилот ≈13,5 млн ₽ gross — цена права не масштабировать.
При широкой ДИ расширяем только контролируемый эксперимент.

Артефакты



Спасибо за внимание

Tг:@Esgrimmm
Почта: jakubovkaja@yandex.ru

Формулы, на которых держатся расчёты

Что считаем	Формула
Выборка для конверсии	$n = (z_{1-\alpha/2} + z_{1-\beta})^2 \cdot [p_1(1-p_1) + p_0(1-p_0)] / (p_1 - p_0)^2$
Выручка на клиента	$Var(Y) = p \cdot (c^2 + 1 - p)$, c — вариация чека; n растёт в $\approx 1 + c^2/(1-p)$ раз
Неухудшение	$n = (z_{1-\alpha} + z_{1-\beta})^2 \cdot 2 \cdot Var(Y) / \delta^2$; δ = доля эффекта × эффект
Граница ошибок судьи	p_U — квантиль Beta(k+1, n−k); при k = 0: $n = \ln \alpha / \ln(1-p) \approx 3/p$
Допустимый охват	$R_{max} = ED_{max} / (p_U \cdot d \cdot \varphi)$, $\varphi = q + (1-q)(1-\pi)$
Цель судьи	raw·(1−r) + Σ остальных остатков ≤ целевая доля ошибок → r
Безубыточность	наименьший δ, при котором накопленный итог за 24 мес. ≥ 0; NPV = Σ CF_t / (1+r)^t
Приоритет риска	RPN = S × O × D (экспертные оценки 1–10)

Время: модель процесса и чувствительность к юридической очереди

Группа	Запуск p10	p50	p90	До результата p50 (окно 14 дн.)	p90
template (pre-approved)	1,11	1,31	1,52	15,6	15,8
new (legal queue)	2,14	2,74	3,62	17,0	17,9
blended	1,18	1,75	3,33	16,0	17,6

Окно наблюдения, дней	As-is, дней	To-be, дней	Сокращение
7	22,9	8,6	63%
14	29,9	15,6	48%
28	43,9	29,6	33%

Примечание: модельный as-is (10,9 д) включает этап генерации гипотезы. Для оценки эффекта автоматизации используется сокращение до p50 to-be (1,3 д).

MODEL ASSUMPTION

Расчёты: process_model.py, legal_queue.py;

Судья: что ловит код на синтетическом корпусе и какой recall нужен от LLM

Класс	Поймано	95% ДИ
Неверная скидка (S3)	92%	82%–97%
Неверная дата (S3)	100%	94%–100%
Неверный минимум (S3)	100%	93%–100%
Пропущено условие (S3)	100%	94%–100%
Выдуманная выгода (S3)	54%	44%–64%
Обращение на «ты» (S2)	63%	50%–74%
Давление (S2)	55%	45%–65%
Безусловное обещание (S2)	47%	35%–59%
Опечатка (S1)	2%	0%–9%
Пробелы (S1)	100%	78%–100%

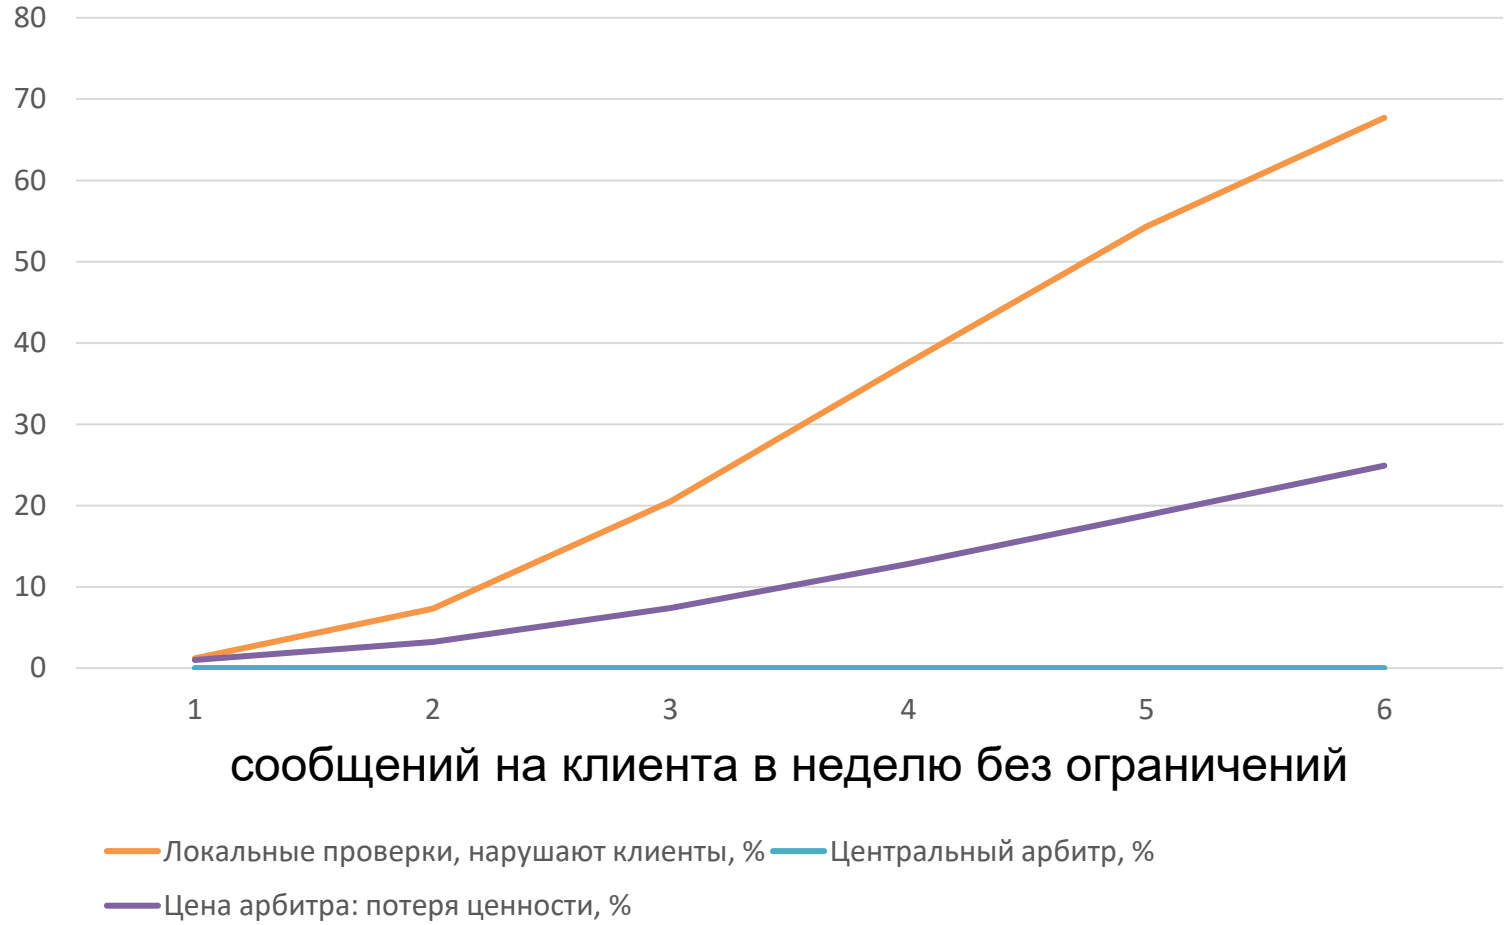
Сырая ошибка агента	Цель итоговой ошибки	Нужен recall судьи
×1.0	1,50%	72%
×1.0	1,10%	82%
×1.0	0,75%	90%
×1.5	1,50%	84%
×1.5	1,10%	91%
×1.5	0,75%	96%

Цель считается на рабочей таксономии ошибок: код закрывает политику, доступность оффера и условия, Judge отвечает за опечатки и тон. Модельный минимум 84,4%; operational target пилота ≥85%.

MODEL ASSUMPTION

Расчёты: judge_benchmark.py, judge_target.py.

Контактная политика: локальные проверки нарушают лимит, центральный арбитр — нет



Политика — общий ресурс клиента

- При 3 сообщениях в неделю локальные проверки нарушают лимит у 20,5% клиентов, арбитр — у 0%, цена арбитра — 7,4% ценности сообщений.
- Арбитр оставляет самые ценные сообщения и не даёт превысить ≤4 в неделю и ≤1 SMS.

MODEL ASSUMPTION

Расчёт: contact_policy.py.

Экономика: траектория, бюджет push и что на самом деле освобождается

Накопленный итог, медиана, млн ₽



Проверка	Результат
Push на пределе политики, 4 млн активных	17,3% бюджета
То же, 12 млн клиентов	52,0% бюджета
Вывод	«65% бюджета в push» недостижимо
Сценарий ручной проверки (120 × 2 ч)	1,4 FTE
Допущение по ролям при полной автоматизации	10,0 FTE

Стоимость пилота	Мин.	Мода	Макс.
team: 5 FTE x 0.35 x 6 months	10,50	10,50	10,50
infrastructure and inference (total)	1,00	2,00	4,00
contingency 8% of team + infrastructure	0,92	1,00	1,16
PILOT GROSS CASH COST	12,42	13,50	15,66

MODEL | ASSUMPTION | DERIVED

Расчёты: economics.py, pilot_cost.py, capacity_budget.py.

Риски и red team: что может сломаться, как это ловим и что ещё не проверено

Риск	S·O·D	До	После	Владелец
Судья и генератор повторяют одни ошибки	8·5·8	320	96	ML/LLM-инженер
Рост отдачи ниже безубыточного порога	8·5·7	280	120	Владелец продукта
Неверная оценка эффекта (малые выборки)	7·6·6	252	63	Аналитик
Судья пропускает критическую ошибку	9·4·7	252	54	ML/LLM-инженер
Выдуманные условия оффера	9·5·5	225	36	ML/LLM-инженер
Нарушение контактной политики	8·6·4	192	8	Бэкенд-разработчик
Дрейф: сезонность, новые офферы	6·5·6	180	54	Инженер данных
Сбой тона бренда	6·5·6	180	54	Владелец продукта

Red team сценарий	Статус
Агент вставляет несуществующую выгоду	PLANNED
Устаревший список отказов	PLANNED
Повторная отправка при ретрае	PLANNED
Инструкция в данных клиента или оффера	PLANNED
Судья повторяет ошибку генератора	PLANNED
Исчерпан бюджет коммуникаций	PLANNED
LLM недоступна	PLANNED
Сезонный дрейф данных	PLANNED

ASSUMPTION

Расчёт: risk_register.py;

Ключевые расчёты имеют тип доказательства и источник

Тип	Значение	Пример на слайдах
FACT	условие кейса	9 дней, 120 кампаний, 1,5% ошибок
DERIVED	арифметика над фактами	труд 17% затрат; предел push при политике
MODEL	расчёт репозитория	запуск ≈1,3 дня; payback 15 / 24 мес. по охвату
ASSUMPTION	допущение с диапазоном	таксономия ошибок, 2 ч проверки, CV чека, δ, очередь юриста
TARGET	цель пилота, не измерение	recall Judge ≥85%; adoption ≥70% среди eligible

FACT MODEL ASSUMPTION DERIVED TARGET

data/processed/evidence_registry.csv; python run_all.py